

## 第七章 线性方程组的数值解




1

## 问题描述


□  $Ax=b$ ,  $A$ 、 $b$ 已知, 求 $x$

□ 应用例子: 立体视觉



思考: 如何从两幅/多幅不同的图片恢复3D信息(深度)?

2



3

$$x_j = P * X_j$$

已知 $x_j$ 和映射矩阵 $P$ 时, 不能求出 $X_j$ ;  
如果还知道 $x'_j = P' * X_j$ 中的 $x'_j$ 和映射矩阵 $P'$ ,  
则可通过求解线性方程组求取

注意: 实际应用时需要考虑各种误差



4

$Ax = b$ ,  $A$ 可逆时, 有两大类方法:

- 直接法: 当 $A$ 为低阶矩阵
- 迭代法: 当 $A$ 为大型稀疏矩阵

若 $A$ 不可逆, 则属于广义逆问题:

有解问题为 $\min \|Ax - b\|$

有唯一解:  $\min \|x\|$

## 第一节 高斯消去法

$$\begin{cases} a_{11}^{(1)}x_1 + a_{12}^{(1)}x_2 + \cdots + a_{1n}^{(1)}x_n = b_1^{(1)} & (1) \\ a_{21}^{(1)}x_1 + a_{22}^{(1)}x_2 + \cdots + a_{2n}^{(1)}x_n = b_2^{(1)} & (2) \\ \vdots & \vdots \\ a_{n1}^{(1)}x_1 + a_{n2}^{(1)}x_2 + \cdots + a_{nn}^{(1)}x_n = b_n^{(1)} & (n) \end{cases}$$

### 一、基本方法

1. (1)不变, (2)~(n)对(1)消元, 消去(2)~(n)中 $x_1$ 项,

设 $a_{11}^{(1)} \neq 0$ , 新(i)=旧(i)- $\frac{a_{i1}^{(1)}}{a_{11}^{(1)}} \times (1)$

$$\begin{cases} a_{11}^{(1)}x_1 + a_{12}^{(1)}x_2 + \cdots + a_{1n}^{(1)}x_n = b_1^{(1)} \\ a_{22}^{(2)}x_2 + \cdots + a_{2n}^{(2)}x_n = b_2^{(2)} \\ \vdots \\ a_{n2}^{(2)}x_2 + \cdots + a_{nn}^{(2)}x_n = b_n^{(2)} \end{cases}$$

2. (1),(2)不变, (3)~(n)对(2)消元, 消去(3)~(n)中 $x_2$ 项。... 经 $n-1$ 步消元后, 得到上三角形方程组。

$$\begin{cases} a_{11}^{(1)}x_1 + a_{12}^{(1)}x_2 + \cdots + a_{1n}^{(1)}x_n = b_1^{(1)} \\ a_{22}^{(2)}x_2 + \cdots + a_{2n}^{(2)}x_n = b_2^{(2)} \\ \vdots \\ a_{nn}^{(n)}x_n = b_n^{(n)} \end{cases}$$

则有

$$x_n = \frac{b_n^{(n)}}{a_{nn}^{(n)}},$$
$$x_i = \frac{\left[ b_i^{(i)} - \sum_{j=i+1}^n a_{ij}^{(i)} x_j \right]}{a_{ii}^{(i)}}, i = n-1, \dots, 2, 1$$



11


二、计算量

$$\text{加减法} \approx \frac{n^3}{3} \quad \text{乘除法} \approx \frac{n^3}{3}$$

三、使用条件:  $a_{kk}^{(k)} \neq 0, k = 1, \dots, n$

□ 定理1: 高斯消去法能进行的充分必要条件是系数矩阵A的各阶顺序主子式均不为0.

$$\Delta_1 = a_{11}, \Delta_2 = \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix}, \dots, \Delta_n = |A|$$



12

四、高斯主元素消去法

1. 列主元素消去法

在  $a_{kk}^{(k)}, \dots, a_{nk}^{(k)}$  中选模最大的元  $a_{i_k k}^{(k)}$ , 对换  $i_k, k$  行;

能够进行的充分必要条件是A可逆 (思考)

2. 行主元素消去法:  $x_k$  和  $x_{j_k}$  也需要互换

3. 全面主元素消去法: 相当于前二者的结合

思考: 比较三种方法, 各方法有何优缺点?



13

□ 第一讲, P45

防止被除数远大于除数

$$\begin{cases} 0.00001x_1 + x_2 = 1 \\ 2x_1 + x_2 = 2 \end{cases}$$

(当先求取  $x_2$ , 再待人第一式中求取  $x_1$  时)



14

## 五、矩阵的三角分解

$Ax = b$ ,  $A$ 为 $n \times n$ 矩阵,  $x, b$ 为向量

□ 定理2: 如果矩阵 $A$ 的 $1 \sim n-1$ 阶顺序主子式都不为0, 则 $A=LU$ , 其中 $L$ 为单位下三角矩阵,  $U$ 为上三角矩阵, 且分解唯一。

证明: “存在性”由高斯消去法可知。

“唯一性”:  $A = LU = L_1 U_1$

则有 $U = (L^{-1}L_1)U_1$

15

其中 $(L^{-1}L_1)$ 为单位下三角矩阵

$U$ 和 $U_1$ 对角线前 $n-1$ 个元不为0

对 $U = (L^{-1}L_1)U_1$ 进行等式两边的比较可得  
 $L^{-1}L_1 = I$

注: 看 $U_{ij}(i > j)$ 即 
$$\begin{bmatrix} U_{21} & U_{31} & \cdots & U_{n1} \\ & U_{32} & \cdots & U_{n2} \\ & & \cdots & \\ & & & \end{bmatrix}$$

16

## 第二节 矩阵的三角分解法

一、直接法  $LUx = b \Rightarrow Ly = b \Rightarrow Ux = y$

即高斯消去法

思考: 如何具体求出 $L$ 和 $U$ ? 计算量?

二、追赶法: 可用于三对角线方程组 (常微分方程边值问题求解)

$$A = \begin{bmatrix} b_1 & c_1 & & & \\ a_2 & b_2 & c_2 & & \\ & & \ddots & \ddots & \\ & & & a_{n-1} & b_{n-1} & c_{n-1} \\ & & & & a_n & b_n \end{bmatrix}$$

17

$$= \begin{bmatrix} \alpha_1 & & & & \\ \gamma_2 & \alpha_2 & & & \\ & \ddots & \ddots & \ddots & \\ & & \gamma_{n-1} & \alpha_{n-1} & \\ & & & \gamma_n & \alpha_n \end{bmatrix} \cdot \begin{bmatrix} 1 & \beta_1 & & & \\ & 1 & \beta_2 & & \\ & & \ddots & \ddots & \\ & & & 1 & \beta_{n-1} \\ & & & & 1 \end{bmatrix}$$

18



$$\left. \begin{array}{l} b_1 = \alpha_1 \\ c_1 = \alpha_1 \beta_1 \\ a_i = \gamma_i \quad i \geq 2 \\ b_i = \gamma_i \beta_{i-1} + \alpha_i \quad i \geq 2 \\ c_i = \alpha_i \beta_i \quad i \geq 2 \end{array} \right\} \Rightarrow \left\{ \begin{array}{l} \alpha_1 = b_1 \\ \beta_1 = \frac{c_1}{b_1} \\ \gamma_i = a_i \\ \alpha_i = b_i - \gamma_i \beta_{i-1} \\ \beta_i = \frac{c_i}{\alpha_i} \end{array} \right.$$

递推过程  $i=2, \dots, n$

19

$$Ly = f$$

$$\begin{bmatrix} \alpha_1 & & & \\ \gamma_2 & \alpha_2 & & \\ & \dots & \ddots & \\ & & \gamma_n & \alpha_n \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} f_1 \\ f_2 \\ \vdots \\ f_n \end{bmatrix}$$

$$\left. \begin{array}{l} \alpha_1 y_1 = f_1 \\ \gamma_i y_{i-1} + \alpha_i y_i = f_i \end{array} \right\} \Rightarrow \begin{array}{l} y_1 = \frac{f_1}{\alpha_1} \\ y_i = \frac{f_i - \gamma_i y_{i-1}}{\alpha_i} \end{array}$$

$$i = 2, 3, \dots, n$$

20

$$Ux = y$$

$$\begin{bmatrix} 1 & \beta_1 & & \\ & 1 & \beta_2 & \\ & & \ddots & \beta_{n-1} \\ & & & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

$$\left. \begin{array}{l} x_n = y_n \\ x_i + \beta_i x_{i+1} = y_i \end{array} \right\} \Rightarrow \begin{array}{l} x_n = y_n \\ x_i = y_i - \beta_i x_{i+1} \end{array}$$

$$i = n-1, n-2, \dots, 1$$

21

三、平方根法（适用于对称正定矩阵）

$$A = A^T \text{ 且 } \forall \text{ 向量 } x \neq 0 \quad x^T A x > 0$$

三角分解

$$U = \begin{bmatrix} u_{11} & & & \\ & u_{22} & & \\ & & \ddots & \\ & & & u_{nn} \end{bmatrix} \begin{bmatrix} 1 & \frac{u_{12}}{u_{11}} & \dots & \frac{u_{1n}}{u_{11}} \\ & 1 & \dots & \\ & & \ddots & \\ & & & 1 \end{bmatrix} = DU_0$$

$$A = LDU_0 \quad A^T = U_0^T D^T L^T$$

由分解的唯一性， $L = U_0^T$  所以  $A = LDL^T$

22

可将 $Ax=b$ 分解, 得到如下两种方法:

平方根法: 
$$\begin{cases} L_1 y = b \ (L_1 = LD^{\frac{1}{2}}) \\ L_1^T x = y \end{cases}$$

或用改进的平方根法:

$$\begin{cases} Lz = b \\ Dy = z \\ L^T x = y \end{cases}$$

思考: 比较二者的计算量及适用性

23

### 第三节 范数与误差分析

#### 一、向量范数

□ 定义: 按某种规则将每个 $x \in R^n$ 对应于一个非负实数 $\|x\|$ , 且满足下列条件:

1.  $\|x\| > 0$  当 $x \neq 0$ 时
2.  $\|cx\| = |c| \cdot \|x\|, \forall c \in R$
3.  $\|x + y\| \leq \|x\| + \|y\|$

则称 $\|x\|$ 为 $x$ 的范数

24

□ 例:

$$\|x\|_1 = \sum_{i=1}^n |x_i|$$

$$\|x\|_2 = \sqrt{\sum_{i=1}^n x_i^2}$$

$$\|x\|_\infty = \max_{1 \leq i \leq n} |x_i|$$

25

#### 二、矩阵范数

□ 定义: 按某种规则将每个 $A \in R^{n \times n}$ 对应一个非负实数 $\|A\|$ , 且满足:

1.  $\|A\| > 0$  当 $A \neq 0$ 时
2.  $\|cA\| = |c| \cdot \|A\|, \forall c \in R$
3.  $\|A + B\| \leq \|A\| + \|B\|$
4.  $\|AB\| \leq \|A\| \cdot \|B\|$

则称 $\|A\|$ 为 $A$ 的范数

若又满足

$$\|Ax\| \leq \|A\| \cdot \|x\|$$

则称 $\|A\|$ 为与向量范数相容的矩阵范数

26

□ 例:

$$\|A\|_1 = \max_{1 \leq j \leq n} \left( \sum_{i=1}^n |a_{ij}| \right) \quad \text{列范数, 与 } \|x\|_1 \text{ 相容}$$

$$\|A\|_\infty = \max_{1 \leq i \leq n} \left( \sum_{j=1}^n |a_{ij}| \right) \quad \text{行范数, 与 } \|x\|_\infty \text{ 相容}$$

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)} \quad \left( \begin{array}{l} \text{最大特征值} \\ \text{与 } \|x\|_2 \text{ 相容} \end{array} \right)$$

27

### 三、误差分析

□ 误差来源

1. 系数扰动  $A, b$  (观测误差或先前步骤带来的误差)

$$\left. \begin{array}{l} Ax = b \\ A \Rightarrow A + \delta A \\ b \Rightarrow b + \delta b \end{array} \right\} x \Rightarrow x + \delta x$$

分析  $\frac{\|\delta A\|}{\|A\|}, \frac{\|\delta b\|}{\|b\|}$  对  $\frac{\|\delta x\|}{\|x\|}$  的影响

28

□ 例1:

$$\begin{bmatrix} 3 & 1 \\ 3.0001 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 4 \\ 4.0001 \end{bmatrix}$$

$$x = (1 \quad 1)^T, \det A = 10^{-4}$$

$$\begin{bmatrix} 3 & 1 \\ 2.9999 & 1 \end{bmatrix} \begin{bmatrix} \tilde{x}_1 \\ \tilde{x}_2 \end{bmatrix} = \begin{bmatrix} 4 \\ 4.0002 \end{bmatrix}$$

$$\tilde{x} = (-2 \quad 10)^T$$

29

$$\square \text{ 例2 } \begin{bmatrix} 10 & 7 & 8 & 7 \\ 7 & 5 & 6 & 5 \\ 8 & 6 & 10 & 9 \\ 7 & 5 & 9 & 10 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 32 \\ 33 \\ 33 \\ 31 \end{bmatrix} \Rightarrow x = \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}$$

$$\delta b = (0.1, -0.1, 0.1, -0.1)^T$$

$$\Rightarrow x + \delta x = (9.2, -12.6, 4.5, -1.1)^T$$

$$A + \delta A = \begin{bmatrix} 10 & 7 & 8.1 & 7.2 \\ 7.08 & 5.04 & 6 & 5 \\ 8 & 5.98 & 9.89 & 9 \\ 6.99 & 4.99 & 9 & 9.98 \end{bmatrix} \Rightarrow x + \delta x = \begin{bmatrix} -81 \\ 137 \\ -34 \\ 22 \end{bmatrix}$$

30

1)  $\delta A = 0, \delta b \neq 0$

$$A(x + \delta x) = b + \delta b$$

由  $Ax = b$ , 有  $A\delta x = \delta b, \delta x = A^{-1}\delta b$

$$\left. \begin{aligned} \|\delta x\| &\leq \|A^{-1}\| \cdot \|\delta b\| \\ \|b\| &\leq \|A\| \cdot \|x\| \end{aligned} \right\} \\ \Rightarrow \frac{\|\delta x\|}{\|x\|} \leq \|A\| \cdot \|A^{-1}\| \cdot \frac{\|\delta b\|}{\|b\|}$$

31

2)  $\delta A \neq 0, \delta b = 0$  时

$$(A + \delta A)(x + \delta x) = b$$

$$x + \delta x = (A + \delta A)^{-1}b$$

又  $x = A^{-1}b$ , 则有

$$\begin{aligned} \delta x &= [(A + \delta A)^{-1} - A^{-1}]b \\ &= [I - A^{-1}(A + \delta A)](A + \delta A)^{-1}b \\ &= -A^{-1}\delta A(x + \delta x) \end{aligned}$$

所以  $\|\delta x\| \leq \|A^{-1}\| \cdot \|\delta A\| \cdot \|x + \delta x\|$

$$\frac{\|\delta x\|}{\|x\|} \approx \frac{\|\delta x\|}{\|x + \delta x\|} \leq \|A^{-1}\| \cdot \|A\| \cdot \frac{\|\delta A\|}{\|A\|}$$

32

思考: 考虑  $\delta A \neq 0, \delta b \neq 0$  时的情形 (相当于两种误差之和)

记  $Cond(A) = \|A\| \cdot \|A^{-1}\|$  为条件数, 如果  $Cond(A)$  较大, 则  $A$  称为病态。

2. 舍入误差 (解方程组各步骤)

与计算机字长、方程组大小有关

舍入误差的事先分析一般比较复杂, 可以采用事后估计。

33

一般的事后估计法:

如果  $\bar{x}$  为  $Ax = b$  的一个近似解,  $x^*$  为精确解,

$$\text{则有 } x^* - \bar{x} = A^{-1}(b - A\bar{x})$$

$$\|x^* - \bar{x}\| \leq \|A^{-1}\| \cdot \|b - A\bar{x}\|$$

$$\text{又 } \frac{1}{\|x^*\|} \leq \frac{\|A\|}{\|b\|}$$

$$\text{有 } \frac{\|x^* - \bar{x}\|}{\|x^*\|} \leq \|A\| \cdot \|A^{-1}\| \cdot \frac{\|b - A\bar{x}\|}{\|b\|}$$

注: 误差来源可以是舍入误差的累积, 也可以是迭代法的方法误差所带来的

38



思考：有无模型误差、方法误差？

实际应用时：

1. 用哪种范数？
2. 如何判断条件数是否很大？
3. 有些情况下可以对矩阵的行列作数乘来改变条件数



## 第四节 迭代法

由  $Ax = b$ （其中  $A$  可逆）推出  $x = Bx + f$

迭代法：  $x^{(k+1)} = Bx^{(k)} + f$

如何推导或构造  $B$ ？


关键：收敛性、误差分析



一、雅可比迭代法  $Ax=b$

$$A = D + L + U$$

$$= \begin{pmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{pmatrix} + \begin{pmatrix} 0 & & & \\ a_{21} & 0 & & \\ \vdots & \ddots & \ddots & \\ a_{n1} & \cdots & a_{n,n-1} & 0 \end{pmatrix} + \begin{pmatrix} 0 & a_{12} & \cdots & a_{1n} \\ & 0 & \ddots & \vdots \\ & & \ddots & a_{n-1,n} \\ & & & 0 \end{pmatrix}$$



$$(D + L + U)x = b$$

$$Dx = -(L + U)x + b$$


$$x = -D^{-1}(L + U)x + D^{-1}b$$

$$\text{令 } B = -D^{-1}(L + U) \quad f = D^{-1}b$$

则有  $x = Bx + f$

迭代公式  $x^{(k+1)} = Bx^{(k)} + f$

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left[ b_i - \sum_{j=1, j \neq i}^n a_{ij} x_j^{(k)} \right]$$



## 二、高斯-赛德尔迭代法 (G-S法)

利用已计算出的  $x_j^{(k+1)}, j = 1, \dots, i-1$  来计算

$x_i^{(k+1)}$

$$x_i^{(k+1)} = \frac{1}{a_{ii}} [b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)}]$$

从矩阵形式上看

$$x^{(k+1)} = D^{-1} [b - Lx^{(k+1)} - Ux^{(k)}]$$

相当于  $(D + L)x^{(k+1)} = b - Ux^{(k)}$

$$x^{(k+1)} = \underbrace{-(D + L)^{-1}U}_{B} x^{(k)} + \underbrace{(D + L)^{-1}b}_f$$

44

## 三、迭代法的收敛性

记误差向量  $\epsilon^{(k)} = x^{(k)} - x^*$

由  $x^{(k+1)} = Bx^{(k)} + f$  和  $x^* = Bx^* + f$  (假定  $x^*$  存在), 有  $\epsilon^{(k+1)} = B\epsilon^{(k)} = \dots = B^{k+1}\epsilon^{(0)}$

□ 定理3: 迭代法  $x^{(k+1)} = Bx^{(k)} + f$  对于任意  $x^{(0)}$  都收敛的充分必要条件是  $\rho(B) < 1$ ,

其中,  $\rho(B) = \max_{1 \leq i \leq n} |\lambda_i|$ , 谱半径

证明: 任意  $\epsilon^{(0)}$  下迭代法收敛  $\Leftrightarrow B^k \rightarrow 0$

考虑将  $B$  相似化简化为 Jordan 标准型

注: 显然,  $\rho(B)$  越小则收敛速度越快

45

□ 定理4: 迭代法收敛的充分条件是  $\|B\| < 1$ , 其中  $\|B\|$  是一种与向量范数相容的矩阵范数。

证明:  $Bx = \lambda x$

$$|\lambda| \cdot \|x\| = \|\lambda x\| = \|Bx\| \leq \|B\| \cdot \|x\|$$

$$\Rightarrow |\lambda| \leq \|B\|$$

所以,  $\rho(B) \leq \|B\|$

47

如何由  $Ax=b$  (其中  $A$  可逆) 构造一般迭代法?

$$Ax = b \Leftrightarrow x = (I - TA)x + Tb, \text{ 其中 } T \text{ 可逆}$$

关键: 构造  $T$

可构造  $T$  为行变换矩阵 (若干初等矩阵的乘积), 使得  $TA$  是上三角矩阵 (类似于列主元素消去法), 甚至是对角形且对角线上的元在  $(0, 2)$  中。

注意: 还要使得  $\|I - TA\| < 1$ , 以方便误差分析

48

□ 结论:

1. 按照上述方法可以对任意 $Ax=b$  (其中 $A$ 可逆) 构造出收敛的迭代公式
2. 但这种构造过程的计算量相当于直接法, 对于大型矩阵并不适用
3. 对于特殊类型的大型矩阵, 一般还是直接套用特别的公式, 如雅可比迭代法和G-S迭代法

51

□ 定义: 设 $A = (a_{ij})_{n \times n}$ , 如果 $|a_{ii}| > \sum_{j=1, j \neq i}^n |a_{ij}|$ , 则称 $A$ 为严格对角优势矩阵。

□ 定理5: 设 $Ax=b$ , 若 $A$ 为严格对角优势矩阵, 则雅可比迭代法和高斯-赛德尔迭代法均收敛。

证明:

1. 证 $\det(A) \neq 0$  即 $A$ 可逆 (存在), 也说明严格对角优势矩阵可逆。

用反证法: 假设 $\det(A) = 0$ , 则 $\exists u \neq 0$ 使 $Au = 0$ 。

52

不妨设 $|u_t| = \max_{1 \leq i \leq n} |u_i| > 0$

则 $\sum_{j=1}^n a_{tj}u_j = 0$

$$a_{tt}u_t = - \sum_{j=1, j \neq t}^n a_{tj}u_j$$

$$|a_{tt}| \cdot |u_t| = \left| \sum_{j=1, j \neq t}^n a_{tj}u_j \right| \leq \sum_{j=1, j \neq t}^n |a_{tj}| \cdot |u_j|$$

$$\leq \sum_{j=1, j \neq t}^n |a_{tj}| \cdot |u_t|$$

所以, 有 $|a_{tt}| \leq \sum_{j=1, j \neq t}^n |a_{tj}|$  矛盾。

53

2. 证 $\rho(B) < 1$

雅可比法:  $B = -D^{-1}(L + U)$

$$\det(\lambda I - B) = \det[\lambda I + D^{-1}(L + U)]$$

$$= \det[D^{-1}(\lambda D + L + U)]$$

$$= \det(D^{-1}) \det(\lambda D + L + U)$$

$$\det(\lambda I - B) = 0 \Leftrightarrow \det(\lambda D + L + U) = 0$$

若 $|\lambda| \geq 1$ , 则 $\lambda D + L + U$ 为严格对角优势阵, 由1可知, 可逆。

所以,  $\det(\lambda D + L + U) = 0 \Leftrightarrow |\lambda| < 1 \Rightarrow \rho(B) < 1$

54

也可直接证明  $\|B\|_\infty < 1$

G-S法:  $B = -(D + L)^{-1}U$

$$\det(\lambda I - B) = \det[(D + L)^{-1}] \det(\lambda D + \lambda L + U)$$

$$\det(\lambda I - B) = 0 \Leftrightarrow \det(\lambda D + \lambda L + U) = 0$$

$\lambda D + \lambda L + U$  在  $|\lambda| \geq 1$  时为严格对角优势矩阵, 可逆, 所以

$$\det(\lambda D + \lambda L + U) = 0 \Rightarrow |\lambda| < 1 \Rightarrow \rho(B) < 1$$

思考: 以上定理中, 雅可比法和G-S法, 哪种的  $\rho(B)$  更小?



55

例:  $\begin{bmatrix} 10 & 3 & 1 \\ 2 & -10 & 3 \\ 1 & 3 & 10 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 14 \\ -5 \\ 14 \end{bmatrix} \Rightarrow x^* = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$

Jacobi	k=0	K=1	K=2	K=3	K=4	K=5	K=6
$x_1^k$	0	1.4	1.11	0.929	0.9906	1.01159	1.000251
$x_2^k$	0	0.5	1.20	1.055	0.9645	0.9953	1.005795
$x_3^k$	0	1.4	1.11	0.929	0.9906	1.01159	1.000251
$\ x^k - x^*\ _\infty$	1	0.5	0.20	0.071	0.035	0.01159	0.005795

Gauss-Seidel	k=0	K=1	K=2	K=3	K=4
$x_1^k$	0	1.4	0.9234	0.99134	0.99154
$x_2^k$	0	0.78	0.99248	1.0310	0.99578
$x_3^k$	0	1.026	1.1092	0.99159	1.0021
$\ x^k - x^*\ _\infty$	1	0.4	0.1092	0.031	0.0085

定理6: 如果A正定对称, 则G-S法收敛。  
(充分性)

定理: 设A对称, 且其对角元素  $a_{ii} > 0, i = 1, \dots, n$ , 则方程组的Jacobi方法收敛的充分必要条件是A和  $2D - A$  均为正定矩阵。



57

定理6: 如果A正定对称, 则G-S法收敛。

证明: 即证  $\rho\{(D + L)^{-1}U\} < 1, L = U^T$

记  $\lambda$  为  $(D + L)^{-1}U$  的特征值, 则有


$$(D + L)^{-1}Uy = \lambda y$$

$$\lambda((D + L)y, y) = (Uy, y)$$

$$\lambda = \frac{(Uy, y)}{(Dy, y) + (Ly, y)}$$

$$\text{记 } (Uy, y) = \alpha + i\beta, (Dy, y) = \gamma > 0$$

$$\text{则有 } (Ly, y) = \alpha - i\beta, 2\alpha + \gamma > 0$$



58



$$\lambda = \frac{\alpha + i\beta}{\gamma + \alpha - i\beta}$$

$$|\lambda|^2 = \frac{\alpha^2 + \beta^2}{(\gamma + \alpha)^2 + \beta^2}$$

分母-分子= $\gamma(\gamma + 2\alpha) > 0$

得证  $|\lambda| < 1$

## 第五节 逐次超松弛迭代法 (SOR法)

对G-S法做加速

G-S法:

$$x^{(k+1)} = D^{-1}[b - Lx^{(k+1)} - Ux^{(k)}]$$

$$= x^{(k)} + \underbrace{D^{-1}[b - Lx^{(k+1)} - (D + U)x^{(k)}]}_{\text{剩余向量}}$$

引入松弛因子 $\omega$

$$(1 - \omega)x^{(k)} + \omega x^{(k+1)} = x^{(k)} + \omega(x^{(k+1)} - x^{(k)})$$

$$x^{(k+1)} = x^{(k)} + \omega D^{-1}[b - Lx^{(k+1)} - (D + U)x^{(k)}]$$

整理可得

$$(D + \omega L)x^{(k+1)} = [(1 - \omega)D - \omega U]x^{(k)} + \omega b$$

$$x^{(k+1)} = (D + \omega L)^{-1}[(1 - \omega)D - \omega U]x^{(k)} + \omega(D + \omega L)^{-1}b$$

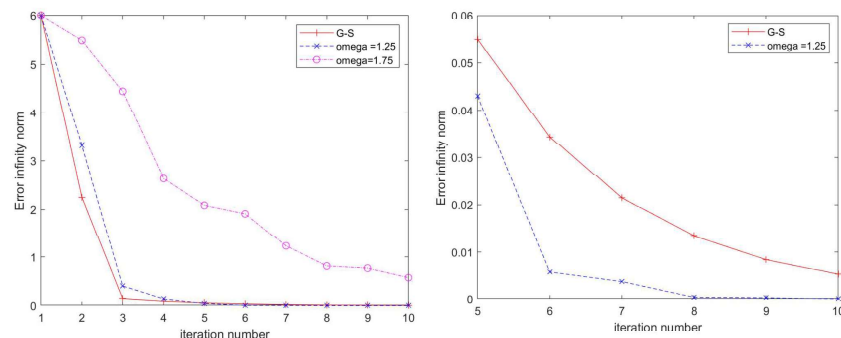
$$= L_{\omega}x^{(k)} + f$$

其中 $L_{\omega} = (D + \omega L)^{-1}[(1 - \omega)D - \omega U]$ 是关键

□ 例:  $\begin{bmatrix} 4 & 3 & 0 \\ 3 & 4 & -1 \\ 0 & -1 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 24 \\ 30 \\ -24 \end{bmatrix} \Rightarrow x^* = \begin{bmatrix} 3 \\ 4 \\ -5 \end{bmatrix}$

$x^{(0)} = [1 \ 1 \ 1]^T$ , G-S, SOR ( $\omega = 1.25, \omega = 1.75$ )

- G-S:  $x^{(10)} = [3.005238 \ 3.995634 \ -5.001091]$
- SOR  $\omega = 1.25$ :  $x^{(10)} = [3.000002 \ 4.000014 \ -5.000022]$
- SOR  $\omega = 1.75$ :  $x^{(10)} = [3.042294 \ 4.006919 \ -5.572998]$



63

□ 定理7: SOR法收敛的必要条件是  $0 < \omega < 2$

证明: 收敛的充要条件是  $\rho(L_\omega) < 1$ , 记  $L_\omega$  的特征值为  $\lambda_i$ , 则  $|\lambda_1 \lambda_2 \cdots \lambda_n| < 1$

$$\begin{aligned}
 |\lambda_1 \cdots \lambda_n| &= |\det(L_\omega)| \\
 &= |\det[(D + \omega L)^{-1}] \det[(1 - \omega)D - \omega U]| \\
 &= \left| \frac{\det[(1 - \omega)D - \omega U]}{\det(D + \omega L)} \right| \\
 &= \left| \frac{(1 - \omega)^n a_{11} a_{22} \cdots a_{nn}}{a_{11} \cdots a_{nn}} \right| \\
 &= |(1 - \omega)^n| < 1 \Rightarrow 0 < \omega < 2
 \end{aligned}$$

64

□ 定理8: 如果  $A$  正定对称且  $0 < \omega < 2$ , 则SOR法收敛。

思考: 如何证明?

$$\omega \text{ 最佳值 } \omega = \frac{2}{1 + \sqrt{1 - \rho^2(B_0)}} > 1$$

其中  $B_0$  为雅可比迭代矩阵

65

迭代法的事后估计法:

$$\|x^{(k)} - x^*\| \leq \frac{\|B\|}{1 - \|B\|} \cdot \|x^{(k)} - x^{(k-1)}\|$$

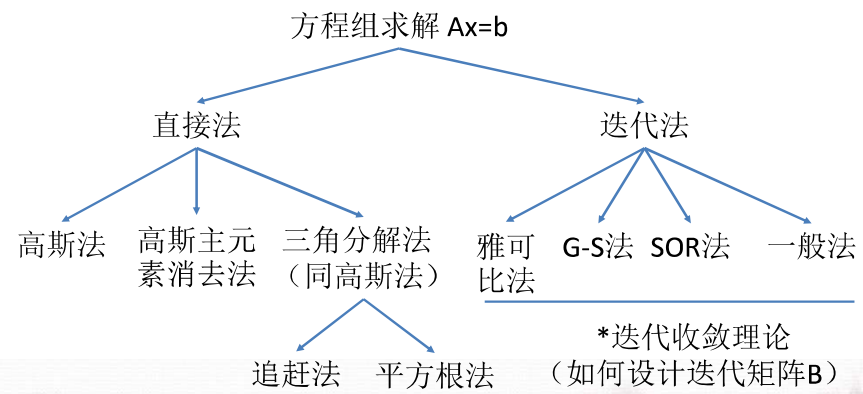
迭代法中舍入误差 (存储误差) 的影响:

$$\|\delta_{k+1}\| \leq \|B\| \cdot \|\delta_k\| + \left\| \begin{pmatrix} \frac{1}{2} \cdot 10^{-m} \\ \vdots \\ \frac{1}{2} \cdot 10^{-m} \end{pmatrix} \right\|$$

思考: 迭代法的计算量?

66

# 方程组求解总结



\*A、b有误差时对x的影响分析